

УДК 004.89

© Д.А. Антипенко, М.Е. Суханов, В.Ю. Радыгин, 2026

Выявление мошеннических транзакций на основе поведенческих и транзакционных признаков финансовых операций

Д.А. Антипенко

студент 4 курса специалитета НИЯУ МИФИ, Москва

Email: antip.ada@yandex.ru

М.Е. Суханов

студент 4 курса специалитета НИЯУ МИФИ, Москва

Email: 7133210@gmail.com

В.Ю. Радыгин

Доцент кафедры финансового мониторинга НИЯУ МИФИ, к.т.н.,
Москва

Email: vyradygin@mephi.ru

Аннотация: в статье рассматривается задача анализа набора данных финансовых транзакций с целью выявления признаков, позволяющих классифицировать операции как мошеннические. Исследуются основные характеристики операций, формируются критерии, позволяющие определить подозрительную активность, оцениваются метрики качества модели.

Ключевые слова: обнаружение мошенничества, финансовые транзакции, машинное обучение, бинарная классификация, логистическая регрессия, случайный лес, градиентный бустинг, ансамблевые методы, ROC-AUC, разработка признаков, дисбаланс классов.

Detection of Fraudulent Transactions Based on Behavioral and Transactional Features of Financial Operations

D.A. Antipenko

4th year undergraduate student at NRNU MEPhI, Moscow

Email: antip.ada@yandex.ru

M.E. Sukhanov

4th year undergraduate student at NRNU MEPhI, Moscow

Email: 7133210@gmail.com

V.Y. Radygin

Assistant Professor of dept. Financial Monitoring, NRNU MEPhI, Moscow

Email: vyradygin@mephi.ru

Abstract: The article addresses the problem of analyzing a dataset of financial transactions in order to identify features enabling the classification of operations as fraudulent. Key transaction characteristics are examined, criteria for detecting suspicious activity are formulated, and model quality metrics are evaluated.

Keywords: fraud detection, financial transactions, machine learning, binary classification, logistic regression, random forest, gradient boosting, ensemble methods, ROC-AUC, feature engineering, class imbalance.

Цифровизация финансовых услуг и рост числа онлайн-операций повышают риск мошеннических транзакций и усложняют их своевременное выявление. Традиционные методы контроля становятся недостаточно эффективными, поэтому всё чаще применяются методы анализа данных и машинного обучения.

Одними из основных подходов, используемых для анализа данных, являются деревья решений, логистическая регрессия и ансамблевые методы (Random Forest, Gradient Boosting), а также нейронные сети [4].

Данные методы позволяют выявлять закономерности в поведении пользователей и характеристиках операций, а также классифицировать транзакции как легитимные или подозрительные.

Целью настоящего исследования является выявление и формализация технических и поведенческих признаков, позволяющих достоверно характеризовать финансовую операцию как мошенническую, на основе данных о транзакции.

В рамках данного исследования сформулированы следующие гипотезы:

1. Международные транзакции совершаются в мошеннических целях значительно чаще, чем внутренние (в результате проведенного исследования исходного набора данных: доля мошенничества среди международных — 6,1%, среди внутренних — 3,5% (рис. 1)).
2. Транзакции, выполненные в необычное время (ночью), характеризуются более высокой долей мошеннических операций (в результате проведенного исследования исходного набора данных: *Unusual_Time* = Yes — 6,1%, No — 3,6%; *is_night* коррелирует с *Fraud_Label* (рис. 2)).

Fraud rate by Is_International_Transaction:

	fraud_rate
Is_International_Transaction	
Yes	0.061373
No	0.035497

Рисунок 1 – Результаты исследования доли мошенничества в зависимости от локации

Fraud rate by Unusual_Time_Transaction:

	fraud_rate
Unusual_Time_Transaction	
Yes	0.061367
No	0.035683

Рисунок 2 – Результаты исследования доли мошенничества в зависимости от времени транзакции

В рамках статьи используется набор данных финансовых транзакций с сайта [kaggle.com](https://www.kaggle.com), содержащий информацию о проведенных операциях. Датасет включает в себя 50000 записей, каждая из которых соответствует одной транзакции. Отдельная операция описывается двадцатью пятью техническими и поведенческими признаками, включая целевую переменную, которая является меткой мошеннической операции. В наборе нет пропущенных значений, что упрощает этап обработки данных.

Таким образом, транзакция описывается следующими группами признаков:

- идентификационные признаки,

- временные признаки,
- количественные признаки,
- категориальные признаки,
- бинарные признаки.

В датасете представлены количественные (Transaction_Amount, Account_Balance и т.д.) и категориальные (Transaction_Type, Merchant_Category и т.д.) признаки, что требует применения методов предварительной обработки данных, таких как кодирование категориальных признаков и нормализация числовых переменных. Данные преобразования позволяют производить анализ различных аспектов транзакции.

Для проведения исследования, признаки были сгруппированы в соответствии с их ролью в процессе выявления мошеннических операций.

- Транзакционные признаки описывают параметры конкретной финансовой операции без учёта информации о пользователе.
- Поведенческие признаки указывают отклонения от обычного/базового поведения пользователя.
- Контекстные признаки информируют об условиях выполнения операции.
- Признаки возможного риска.
- Целевая переменная: *Fraud_Label* – бинарный индикатор (Fraud — мошенническая транзакция, Normal — легитимная транзакция), указывающий соответствует ли операция мошеннической или нет. Является зависимой переменной при построении модели классификации.

В наборе данных наблюдается выраженный дисбаланс классов: из 50 000 транзакций мошенническими являются 2 423, то есть около 5%. Поэтому обычная оценка ассигасу не является достаточной метрикой качества. В задаче выявления мошенничества особенно важно снижать число ложноотрицательных результатов, поскольку пропущенная вредоносная операция приводит к финансовым потерям. При этом необходимо контролировать и ложноположительные срабатывания, так как ошибочная блокировка легитимной операции ухудшает клиентский опыт. По этой причине основной метрикой оптимизации выбрана характеристика ROC-AUC, а дополнительно анализируются оценки Precision, Recall и F1-score [6].

Задача исследования формулируется как бинарная классификация: по набору признаков транзакции необходимо определить вероятность её принадлежности к классу мошеннических операций. Целевая

переменная *Fraud_label* кодируется как 1 для мошеннической транзакции и 0 для легитимной.

На этапе предобработки были проверены пропущенные значения, удалены 4 записи без значения целевой переменной *Fraud_Label*, а значения *Normal* и *Fraud* закодированы как 0 и 1. Признаки *Transaction_Date* и *Transaction_Time* были объединены в единый временной признак *Transaction_DateTime*, после чего исходные столбцы даты и времени были исключены из набора данных.

Для повышения информативности данных были сформированы дополнительные признаки, отражающие временные, поведенческие и контекстные особенности транзакций. Из *Transaction_DateTime* были выделены *hour* — час совершения операции, *day_of_week* — день недели, *is_night* — признак ночной транзакции, и *is_weekend* — признак операции в выходной день.

Для анализа финансового поведения клиента рассчитаны *amount_to_avg_ratio*, показывающий отношение суммы операции к средней сумме транзакций клиента, и *amount_to_balance_ratio*, отражающий долю операции от текущего баланса счёта. Для выявления географических аномалий введён *is_location_mismatch*, указывающий на нетипичную локацию операции.

Также сформированы комбинированные признаки риска: *intl_and_unusual* — международная транзакция в необычных условиях, *intl_or_unusual* — наличие международного характера операции или необычного времени, *new_merchant_and_intl* — международная транзакция у нового получателя или продавца. На их основе рассчитан обобщённый показатель *risk_score*, характеризующий совокупный уровень риска транзакции.

Идентификационные признаки *Customer_ID*, *Merchant_ID*, *Device_ID* и *Transaction_ID* были исключены, поскольку содержали большое число уникальных значений и могли привести к запоминанию объектов вместо выявления общих закономерностей.

После удаления идентификационных признаков данные были разделены на обучающую и тестовую выборки в пропорции 80/20 со стратификацией по целевой переменной. Для линейных моделей применялись масштабирование числовых признаков и *one-hot encoding* категориальных переменных. Для древовидных моделей использовалось порядковое кодирование категориальных признаков без масштабирования числовых переменных.

Для оценки качества использовались метрики *Precision*, *Recall*, *F1-score* и *ROC-AUC* [5]. *Precision* показывает долю действительно мошеннических операций среди всех операций, отмеченных моделью как мошеннические. *Recall* отражает способность модели находить

реальные мошеннические транзакции. *F1-score* позволяет оценить баланс между *Precision* и *Recall*. Основной метрикой выбрана *ROC-AUC*, поскольку она показывает способность модели разделять мошеннические и легитимные операции при разных порогах классификации и подходит для несбалансированных данных [1; 3].

Перед обучением модели был проведен анализ получившихся данных. Была рассчитана корреляция числовых признаков с целевой переменной *Fraud_label* для выявления наиболее информативных из них. Также оценивалось влияние категориальных признаков на вероятность мошенничества путем расчета доли мошеннических операций в разрезе различных категорий.

В рамках данного исследования для решения задачи бинарной классификации были использованы четыре алгоритма: логистическая регрессия, случайный лес, градиентный бустинг (*HistGradientBoosting*) и стекинг-ансамбль (*StackingClassifier*). Каждый из них основан на своих принципах и обладает своими особенностями [8].

- **Логистическая регрессия:** является базовым методом бинарной классификации, основанным на линейной комбинации признаков. Модель оценивает вероятность принадлежности объекта к положительному классу с использованием логистической (сигмоидной) функции [6].

$$P(y=1 \mid X) = \frac{1}{1 + e^{-(\omega^T X + b)}},$$

где ω — вектор весов признаков, b — смещение.

Основные особенности метода:

- интерпретируемость результатов;
- высокая скорость обучения;
- ограничение линейной зависимостью между признаками целевой переменной.

Логистическая регрессия хорошо работает в задачах, где зависимости между признаками и целевой переменной близки к линейным.

- **Случайный лес:** ансамблевый метод, основанный на построении множества деревьев решений. Каждое дерево обучается на случайной подвыборке данных и использует случайное подмножество признаков. Окончательный прогноз формируется путем агрегирования результатов всех деревьев (например, путем голосования) [2]. Основные характеристики метода:

- возможность моделировать сложные нелинейные зависимости;
- устойчивость к переобучению путем усреднения результатов;
- возможность оценивать важность функций;
- низкая чувствительность к масштабированию данных.

Случайный лес эффективно работает с табличными данными и широко используется в задачах обнаружения мошенничества.

- **Градиентный бустинг:** ансамблевый метод, основанный на последовательном построении моделей, обычно деревьев решений. Каждая новая модель обучается исправлять ошибки предыдущих, а качество улучшается за счёт минимизации функции потерь с использованием градиентного спуска. Метод позволяет выявлять сложные нелинейные зависимости и часто показывает высокую точность на табличных данных, однако чувствителен к настройке гиперпараметров и требует больших вычислительных ресурсов [7].
- **Стекинг-ансамбль:** метод ансамблирования, при котором несколько базовых классификаторов обучаются независимо, а их предсказания используются как признаки для финального мета-классификатора. В данной работе базовыми моделями являются логистическая регрессия, случайный лес и градиентный бустинг, а мета-классификатором — логистическая регрессия. Такой подход снижает систематическую ошибку и повышает качество классификации, но требует дополнительных вычислительных затрат [5].

Подбор гиперпараметров выполнялся с использованием *Optuna* и стратифицированной кросс-валидации, целевой метрикой оптимизации была *ROC-AUC*. После обучения модели оценивались на тестовой выборке по метрикам *ROC-AUC*, *Precision*, *Recall* и *F1-score*. Лучшей считалась модель с максимальным *ROC-AUC* и приемлемым балансом между *Recall* и *Precision*.

Заключение

В ходе исследования была решена задача бинарной классификации финансовых транзакций на мошеннические и легитимные. На основе датасета из 50 000 записей сформированы информативные группы признаков, подтверждены гипотезы о повышенном риске международных и ночных транзакций, введён обобщённый показатель *risk_score*.

Сравнение четырёх алгоритмов машинного обучения с оптимизацией гиперпараметров по метрике ROC-AUC позволило выявить наиболее эффективную модель, пригодную для применения в системах автоматического финансового мониторинга.

Библиографический список

1. Accuracy improving of pre-trained neural networks by fine tuning [Электронный ресурс]. – URL: <https://cyberleninka.ru/article/n/accuracy-improving-of-pre-trained-neural-networks-by-fine-tuning/viewer> (дата обращения: 10.05.2026).
2. Алгоритм машинного обучения адаптивный случайный лес и его применение [Электронный ресурс]. – URL: <https://cyberleninka.ru/article/n/algoritm-mashinnogo-obucheniya-adaptivnyy-sluchaynyy-les-i-ego-primenenie/viewer> (дата обращения: 03.05.2026).
3. Анализ чувствительности метрик бинарной классификации к дисбалансу данных [Электронный ресурс]. – URL: <https://cyberleninka.ru/article/n/analiz-chuvstvitelnosti-metrik-binarnoy-klassifikatsii-k-disbalansu-dannyh/viewer> (дата обращения: 06.05.2026).
4. Аналитический обзор методов оценки качества алгоритмов классификации в задачах машинного обучения [Электронный ресурс]. – URL: <https://cyberleninka.ru/article/n/analiticheskiy-obzor-metodov-otsenki-kachestva-algoritmov-klassifikatsii-v-zadachah-mashinnogo-obucheniya/viewer> (дата обращения: 10.05.2026).
5. Исследование эффективности процедуры стекинга при решении задач классификации [Электронный ресурс]. – URL: <https://cyberleninka.ru/article/n/issledovanie-effektivnosti-protsedury-stekinga-pri-reshenii-zadach-klassifikatsii/viewer> (дата обращения: 04.05.2026).
6. Матрица путаницы и ROC-кривая как эффективное средство для оптимизации классификаторов машинного обучения [Электронный ресурс]. – URL: <https://cyberleninka.ru/article/n/roc-krivaya-i-matritsa-putanitsy-kak-effektivnoe-sredstvo-dlya-optimizatsii-klassifikatorov-mashinnogo-obucheniya/viewer> (дата обращения: 03.05.2026).
7. Применение модели градиентного бустинга в задачах регрессии [Электронный ресурс]. – URL: <https://cyberleninka.ru/article/n/primenenie-modeli-gradientnogo-bustinga-v-zadachah-regressii/viewer> (дата обращения: 10.05.2026).
8. Сравнительный обзор методов машинного обучения для анализа больших данных [Электронный ресурс]. – URL: <https://cyberleninka.ru/article/n/sravnitelnyy-obzor-metodov-mashinnogo-obucheniya-dlya-analiza-bolshih-dannyh/viewer> (дата обращения: 10.05.2026).